





TRABALHO FINAL - EDA2 2026.1



Grupo 2 - FinGraph Analytics




INTEGRANTES:



CAIO VILAS BOAS
MIRANDA (232001380)



CARLOS HENRIQUE DE
PAIVA MUNIS (221022480)




DAVI RODRIGUES
NUNES (232014413)



FELIPE LOPES PEDROZA
(231026330)



GUSTAVO OKI DE FREITAS
RODRIGUES LEITE (231034716)



PROBLEMA

- **Cenário:** Corpus de ~53.000 manchetes financeiras (CNBC, Reuters, Guardian, de 2018 a 2020);
- **Pergunta:** Quais são os grandes temas econômicos que emergem dessas notícias? Quais termos sempre aparecem juntos?
- **Desafio:** Processar volume alto de texto, identificar relações semânticas entre palavras e visualizar os agrupamentos de forma clara. Tudo em C puro, sem bibliotecas externas.

MODELAGEM DO GRAFO



Grafo não-direcionado ponderado:

- Vértices: termos selecionados (top 600 por TF-IDF, após filtro de frequência de documento DF);
- Arestas: par de termos que co-ocorre em pelo menos um documento;
-
- Peso da aresta: PPMI — Positive Pointwise Mutual Information.



Fórmula PPMI:

$$PPMI(u,v) = \max(0, \log(\text{cooc}(u,v) \times N / (\text{freq}_u \times \text{freq}_v))),$$

onde N = número de documentos, freq = nº de docs em que o termo aparece.

MODELAGEM DO GRAFO




Decisões de projeto:

- Lista de adjacência (memória proporcional às arestas, não ao vocabulário²);
- Vocabulário: array ordenado + busca binária (sem hash table — restrição);
- Limiar de corte: mantém apenas arestas com PPMI ≥ 2.0 .



SOLUÇÃO

Pipeline em 5 etapas:


1. Leitura do CSV: carrega até 60.000 documentos (data, título, resumo);
 2. Pré-processamento: normalização UTF-8, remoção de stopwords e ruído de domínio, tokenização;
 3. Seleção de termos: DF filter (0.3%–85%), ranking TF-IDF → top 600 termos;
 4. Construção do grafo PPMI: co-ocorrência por documento, cálculo e limiarização;
 5. Análise e saída: relatório no terminal + HTML interativo.
- 



SOLUÇÃO


Algoritmos aplicados:

Algoritmo	Propósito
BFS + componentes conexas	Descobrir grupos/temas
Bron-Kerbosch (com pivô)	Maior clique (núcleo temático mais denso)
Prim máximo	Árvore geradora (espinha dorsal do grafo)
Grau, distribuição	Relevância dos termos




IMPLEMENTAÇÃO

- **Linguagem:** C (sem C++, sem bibliotecas externas de análise);
- **Estrutura do projeto:**
 - src/
 - main.c ← orquestrador
 - config.h ← constantes globais
 - estruturas/ ← grafo (lista adj.), fila manual
 - algoritmos/ ← BFS, componentes, Bron-Kerbosch, Prim
 - util/ ← tokenização, CSV, datas
 - pipeline/ ← vocabulário (TF-IDF), PPMI, relatório, HTML
 - tests/ ← 9 suítes, 145 casos de teste



IMPLEMENTAÇÃO

- Destaques de implementação:
 - Ordenação: selection sort (restrição do professor, sem `stdlib qsort`);
 - Busca no vocabulário: busca binária sobre array ordenado;
 - Sem `malloc` em stack: arrays grandes alocados em heap (evita stack overflow com 60k docs);
 - PPMI bug crítico corrigido: denominador unificado em `n_docs` (não `total_pares`).



EXEMPLOS ENTRADA E SAÍDA

Entrada: `./fingraph dados/convertidos/cnbc_convertido.csv 2.0 600 --html grafo.html`

(CSV com 53.000 manchetes, limiar PPMI 2.0, top 600 termos)

```
~/Dow/EDA2-/EDA2--Trabalho-Final main ./fingraph dados/convertidos/cnbc_convertido.csv 2.0 600 --html grafo.html

#####
GraphFinance – Grafo de Coocorrência Financeiro
Corpus : dados/convertidos/cnbc_convertido.csv
Limiar PPMI : 2.00 | Termos TF-IDF: 600
#####

[1/6] Corpus carregado      : 53330 documentos
[2/6] Vocabulário (busca bin.): 32327 termos únicos
[3/6] Após filtro de DF    : 1240 termos (min=0%, max=85%)
[4/6] Termos selecionados TF-IDF: 600
[5/6] Grafo PPMI completo  : 600 vértices, 27321 arestas
[6/6] Após limiar PPMI 2.00 : 361 arestas restantes

[HTML] Grafo exportado para grafo.html (310 nós, 361 arestas) – abra no navegador

=====
[01] GRAU DOS VERTICES
=====
Termo          Grau
-----
vehicles       11
```

EXEMPLOS ENTRADA E SAÍDA

Saída (Terminal):

Documentos lidos: 53.330; **Vocabulário:** 32.327 termos; **Termos aceitos** (DF): 1.240; **Termos no grafo:** 600; **Arestas** ($\text{PPMI} \geq 2.0$): 361; **Componentes conexas:** 12 grupos; **Maior clique** (5): fed, rates, inflation, rate, interest.

```
[07] RESUMO FINAL
```

```
=====
Documentos analisados      : 53330
Vocabulário total         : 32327 termos
Após filtro de DF         : 1240 termos
Termos no grafo (TF-IDF)  : 600
Arestas (pós-limiar PPMI) : 361
Limiar PPMI aplicado       : 2.00
```

```
#####
```


```
GraphFinance · UnB 2026
```

```
#####
```

EXEMPLOS ENTRADA E SAÍDA

Saída (HTML interativo):

- 310 nós, 361 arestas ponderadas;
- Painel lateral com grupos nomeados;
- Cores por grupo/tema, tamanho por relevância (grau);
- Botão "Destacar maior clique";



ANÁLISE DOS RESULTADOS

Grupos identificados (principais componentes conexas):

Grupo	Tamanho	Termos representativos	Tema
1	~120 termos	fed, rates, inflation, rate, interest	Política monetária
2	~45 termos	trade, china, tariff, deal, exports	Guerra comercial EUA-China
3	~30 termos	tech, shares, stock, earnings, revenue	Mercado de ações
4	~20 termos	oil, energy, opec, crude, prices	Commodities energéticas
...	...	...	...

ANÁLISE DOS RESULTADOS

Interpretação:

- O maior clique (fed, rates, inflation, rate, interest) confirma que a narrativa dominante é o ciclo de juros do Federal Reserve;
- A separação em componentes mostra temas editorialmente distintos (commodities vs. tech vs. macro);
- Limiar PPMI 2.0 equilibra densidade e qualidade: limiar menor torna o grafo "bagunçado"; maior isola demais os grupos.

USO DE LLM

Claude (Anthropic) como parceiro de desenvolvimento:

Área	Como foi usado
Debugging matemático	Identificou o bug do denominador PPMI: a LLM revisou a fórmula e apontou que total_pares e n_docs não são intercambiáveis como denominadores
Refatoração arquitetural	Propôs a decomposição de main.c (765 linhas) em módulos: pipeline/, estruturas/, algoritmos/, util/
Geração de testes	Escreveu os 12 casos de teste de test_coocorrencia.c, incluindo testes de monotonia e de independência estatística
Visualização HTML	Gerou o módulo html.c completo: vis-network, layout de força, painel de grupos, botão de clique máximo

USO DE LLM


Claude (Anthropic) como parceiro de desenvolvimento:

Área	Como foi usado
Filtro de ruído	Sugeriu adicionar termos de domínio ("cramer", "lightning", "mad") como stopwords ao identificar que o programa "Mad Money" da CNBC formava grupo artificial
Documentação	Reescreveu o README.md e este script de apresentação

Todo o código foi revisado e entendido pelo grupo antes de ser incorporado.

CONCLUSÃO

- Grafos de coocorrência são uma ferramenta poderosa para análise de corpus sem modelos de linguagem pesados;
- PPMI + limiarização produz grafos semanticamente coerentes mesmo em C puro;
- Componentes conexas + Bron-Kerbosch juntos identificam tanto os grupos amplos quanto o núcleo mais coeso de cada tema;
- A visualização HTML torna os resultados acessíveis. Qualquer pessoa abre no navegador sem instalar nada.



OBRIGADO!

